

FisheyeMotion: 面向鱼眼视频运动区域抽象的多源深度证据融合与双路线评估

Zhuang Jiahan
Tongji University

https://github.com/FerdinandClooney/fisheye_motion

Abstract

鱼眼视频以大视场覆盖换取强非线性投影畸变，使同一三维运动在图像中心与边缘呈现显著不同的尺度、边界和光流统计。本文提出 **FisheyeMotion**，一个面向相邻鱼眼帧运动区域抽象与短时目标跟踪的 GPU 深度学习系统。系统融合 RAFT 光流、YOLO26-seg 实例先验、DINOv2 语义变化、边界提示、鱼眼几何编码、监督式 FisheyeMotionNet、测试时增强不确定性融合与 SAM2.1 掩膜细化。我们进一步实现两条可复现实验路线：直接在原始鱼眼域处理，以及先校正再反投影回鱼眼域评估。完整 pipeline 在 130 个有效样本上完成特征缓存、训练、消融、区域评估和路线对比；测试集包含 19 个样本。最新运行显示，原始鱼眼域完整模型取得 IoU 0.2959、Precision 0.3352、Recall 0.5941、F1 0.3758，显著优于 FrameDiff、Farneback 和 RAFT-only，并在边缘区域达到 F1 0.2916。与之相比，校正路线完整模型 F1 仅为 0.0883，说明在本数据规模和当前反投影误差下，保持原始鱼眼域并显式注入几何先验比前置校正更可靠。

1 引言

运动区域抽象是视频理解、智能交通监控和移动机器人感知中的基础任务。与针孔相机相比，鱼眼相机能够覆盖更宽视场，但其径向畸变会改变目标形状、像素速度和局部纹理统计。中心区域目标通常具备较稳定的外观和边界，而边缘区域目标被压缩或拉伸，光流幅值与真实运动不再简单对应，运动边界也更容易与静态结构、车体反光和镜头遮挡混淆。

传统帧差、Farneback 光流和单一深度光流阈值都难以处理上述问题。仅依赖实例分割也不充分，因为检测模型能定位物体，却不能判断物体是否相对场景发生运动。本文的核心观点是：鱼眼运动分割需要联合建模运动、实例、语义、边界和投影几何，而不是把任务退化爲某一种证据的阈值化。

本文贡献如下：

- 构建完整 GPU pipeline，覆盖数据校验、RAFT/YOLO/DINO 特征缓存、监督训练、SAM2.1 细化、区域评估、短时跟踪和可复现脚本。
- 提出多源证据融合的 FisheyeMotionNet，将 RGB pair、帧差、深度光流、实例 mask、语义变化、边界提示和鱼眼几何编码统一到监督分割框架。

- 实现原始鱼眼域与校正域两条路线，并在相同鱼眼 GT 上公平比较，揭示当前任务中前置校正会显著损害最终掩膜质量。

2 相关工作

光流估计。RAFT [5] 通过 all-pairs correlation volume 和循环更新模块显著提高稠密光流质量，SE-RAFT [6] 进一步探索效率与精度平衡。本文使用 RAFT large 作为强运动底座，但避免直接阈值化光流，而是将其作为可学习输入和短时传播线索。

提示分割与视频分割。SAM2 [4] 将 promptable segmentation 扩展到图像和视频，Cutie [1] 则强调对象记忆在视频目标分割中的作用。本文任务主要由相邻帧 pair 构成，因此不追求长时记忆建模，而是利用 SAM2.1 对高置信运动提示进行边界 densification。

自监督语义表征。DINOv2 [3] 的 patch token 具有良好的类别无关语义聚合能力。受 Segment Any Motion [2] 将运动线索、DINO 表征与 SAM 掩膜组合的思想启发，我们将 DINOv2 semantic saliency 和前后帧 semantic change 作为小样本运动分割的补充证据。

3 方法

3.1 鱼眼几何编码

给定每个样本的标定 JSON，我们根据主点 (c_x, c_y) 生成归一化半径与方向编码：

$$r(x, y) = \frac{\sqrt{(x - c_x)^2 + (y - c_y)^2}}{r_{\max}}, \quad g(x, y) = [r, \sin \theta, \cos \theta]. \quad (1)$$

该几何图不直接校正图像，而是作为网络输入，让模型学习不同半径处运动证据的可信度。评估时按 $r < 0.35$ 、 $0.35 \leq r < 0.70$ 、 $r \geq 0.70$ 划分中心、中间和边缘区域。

3.2 多源证据提取

对每个相邻帧 pair，系统缓存以下证据：RAFT 输出 $u, v, |f|, \angle f$ ；YOLO26-seg 输出实例 objectness mask；DINOv2 输出当前帧 saliency 和前后帧 semantic change；边界提示由 Canny 边缘与帧差 Sobel 梯度组合得到。真实缓存证据如图 2 所示。

Motion is not decided by a single threshold: geometric distortion, dense flow, object priors, semantic change and boundary evidence are learned jointly.




Figure 1: FisheyeMotionNet 总体架构。系统联合 RAFT 光流、YOLO 实例先验、DINOv2 语义变化、边界提示和鱼眼几何图，经 FisheyeMotionNet 预测运动概率，再通过不确定性融合与 SAM2.1 prompt refinement 生成最终运动掩膜和短时轨迹。

3.3 FisheyeMotionNet

FisheyeMotionNet 是一个轻量 Attention U-Net 风格分割网络，输入为：

$$X = [I_{t-1}^{rgb}, I_t^{rgb}, |I_t - I_{t-1}|, f_{RAFT}, M_{YOLO}, P_{DINO}^{sal}, P_{DINO}^{chg}, P_{edge}, g(x, y)]. \quad (2)$$

训练目标由边界加权 BCE、Dice loss 和 boundary loss 组成：

$$\mathcal{L} = \mathcal{L}_{BCE}^w + \lambda_d \mathcal{L}_{Dice} + \lambda_b \mathcal{L}_{Boundary}. \quad (3)$$

边界权重由 GT 膨胀边缘生成，用于缓解小目标和细边界在背景中被淹没的问题。

3.4 不确定性融合与 SAM2.1 细化

推理阶段使用原图和水平翻转两路 TTA，预测均值作为 P_{net} ，标准差作为 epistemic uncertainty U 。融合分定义数定义为：

$$S = w_n P_{net} + w_f P_{flow} + w_y P_{yolo} + w_d P_{dino} + w_e P_{edge} - w_u U. \quad (4)$$

高置信点、运动连通域框和 YOLO 框共同组成 SAM2.1 prompts。该设计使 SAM2.1 主要负责边界细化，运动属性仍由多源证据和监督网络决定。

4 实验设置

数据集为 data/homework2，包含当前帧、前一帧、GT 掩膜和鱼眼标定文件。最新完整运行共验证 130 个完整样本，图像原始尺寸为 1280×966 。训练/验证/测试比例为 70/15/15，测试集 19 个样本。所有深度模块均强制使用 GPU；本次运行环境为 NVIDIA GeForce RTX 3060 Laptop GPU, PyTorch 2.11.0+cu128。完整命令为：

Table 1: 原始鱼眼域测试集主结果。所有数值来自本次完整 pipeline 生成的 outputs/route_comparison.csv。

Method	IoU	Prec.	Rec.	F1
FrameDiff	0.0376	0.0534	0.4058	0.0658
Farneback	0.0147	0.0298	0.1072	0.0275
RAFT-only	0.0264	0.0512	0.1150	0.0462
YOLO-only	0.2384	0.2588	0.5933	0.3292
FisheyeMotionNet	0.2718	0.3549	0.4504	0.3589
UncertaintyFusion	0.2727	0.3595	0.4433	0.3596
Full	0.2959	0.3352	0.5941	0.3758

```
bash scripts/run_full_pipeline.sh
```

该脚本依次执行数据校验、鱼眼域特征缓存、鱼眼域训练评估、校正域特征缓存、校正域训练评估、消融、区域评估和路线对比。

5 结果

5.1 主结果

表 1 表明，传统方法在鱼眼视频中显著受限。FrameDiff 具有较高召回但 precision 极低，说明其将光照变化、静态边缘和反光区域误判为运动。Farneback 与 RAFT-only 的 F1 均低于 0.05，说明仅依赖光流幅值不足以解决鱼眼畸变和实例语义混淆。YOLO-only F1 达到 0.3292，证明实例先验很关键，但它缺少运动属性判断。完整模型在保持高召回的同时提升综合 F1 至 0.3758。

5.2 双路线比较

表 2 给出本次实验最重要的结论：校正并没有带来收益，反而显著降低所有强方法的表现。完整模型从鱼眼域 F1 0.3758 降至校正域 F1 0.0883。我们认为原因




Figure 2: 真实模型证据面板。该图展示最终模型实际使用的当前帧、RAFT 光流、YOLO objectness、DINOv2 semantic change、边界先验、最终预测、GT 与误差图。红色为 FP，蓝色为 FN，绿色为 TP。




Figure 3: 鱼眼域方法 F1 对比。深度融合方法显著优于传统帧差、Farneback 和单独光流路线。

包括三点：第一，校正过程会在边缘区域引入插值模糊和空洞；第二，深度先验模型在校正域与原始标注域之间存在反投影误差；第三，小样本训练下，显式几何编码比额外图像变换更稳定。

Table 2: 原始鱼眼域与校正域路线对比。校正域预测被反投影回鱼眼域后与同一 GT 评估。

Route	Method	IoU	Prec.	Rec.	F1
Fisheye	Full	0.2959	0.3352	0.5941	0.3758
Rectified	Full	0.0562	0.0963	0.1278	0.0883
Fisheye	FisheyeMotionNet	0.2718	0.3549	0.4504	0.3589
Rectified	FisheyeMotionNet	0.0489	0.1530	0.0879	0.0850
Fisheye	YOLO-only	0.2384	0.2588	0.5933	0.3292
Rectified	YOLO-only	0.0498	0.0914	0.0708	0.0737

5.3 区域分析

区域结果显示，完整模型对边缘区域的提升最明显。单体 FisheyeMotionNet 的边缘 F1 为 0.1340，而 Full 模型达到 0.2916，说明 SAM2.1 细化、YOLO 框提示和多源融合对畸变强烈区域具有互补作用。相比之下，校正域 Full 在中心、中间、边缘均明显较低，进一步支持原始鱼眼域处理的选择。




Figure 4: 双路线 F1 对比。原始鱼眼域路线在多数方法上均优于先校正再反投影路线。

Table 3: 区域 F1。边缘区域最能反映鱼眼畸变建模能力。

Method	Center	Middle	Edge
YOLO-only	0.3324	0.2811	0.2283
FisheyeMotionNet	0.3950	0.2970	0.1340
UncertaintyFusion	0.3953	0.2956	0.1300
Full	0.3898	0.3404	0.2916
Rectified Full	0.0368	0.0980	0.0536

5.4 消融分析

消融结果揭示了几个有意义的现象。首先，w/o RAFT 和 w/o geometry 的全图 F1 略高于 Full，但边缘 F1 明显下降，说明全图平均值会被中心和中间区域主导，而边缘区域更依赖运动与几何证据。其次，去除 DINOv2 后边缘 F1 从 0.2916 降至 0.1034，表明语义变化对困难区域有明显帮助。最后，w/o YOLO 几乎失效，说明在本数据规模下，实例先验仍是稳定召回运动目标的关键。

6 定性结果与失败模式

图 6 展示了代表性样本的当前帧、GT、预测和误差图。模型通常能捕获车辆、行人和靠近边缘的运动目标；主要失败来自三类情况：大面积车体反光导致 FP，远处小目标或细长行人导致 FN，边缘区域反投影和插值误差导致校正路线掩膜破碎。

7 讨论

本次完整运行给出两个工程上重要的结论。第一，鱼眼运动分割的瓶颈不是单个模型是否足够强，而是证据之间如何约束。YOLO-only 能提供高召回但缺少运动性；RAFT-only 能提供运动但缺少实例和语义；SAM2-FrameDiff 受 prompt 质量限制。第二，前置校正并非天然更优。校正能让图像局部更接近针孔视角，但也会改变纹理、边界和 mask 对齐方式；当最终评估仍在鱼眼 GT 上进行时，反投影误差会直接损害像素级指标。

Table 4: 鱼眼域模块消融。数值为测试集全图 F1 和边缘 F1。

Variant	All F1	Edge F1
Full	0.3758	0.2916
w/o RAFT	0.3878	0.1646
w/o geometry	0.3851	0.2032
w/o edge	0.3617	0.1224
w/o DINO	0.3225	0.1034
w/o YOLO	0.0132	0.0000

Region-aware F1: what each module contributes




Figure 5: 区域感知消融矩阵。行为方法或去模块版本，列为全图、中心、中间和边缘 F1。

8 局限与未来工作

当前数据规模较小，测试集只有 19 个样本，结论仍需在更多天气、光照和相机型号上验证。其次，跟踪评估主要是短时关联，尚未覆盖 IDF1、HOTA 或长时遮挡恢复。第三，Full 模型对 YOLO 先验依赖较强，w/o YOLO 消融几乎失效。后续工作可引入长视频记忆网络、DINO/SAM 伪标签扩增、畸变感知 transformer decoder，以及联合优化校正域和鱼眼域的一致性约束。

9 结论

本文完成了一个可复现的鱼眼视频运动区域抽象系统。最新完整 pipeline 表明，在本数据集和当前实现下，直




Figure 6: 定性比较。 每行展示一个测试样本，包含当前帧、GT、Full 模型预测和像素级误差。




Figure 7: 短时跟踪与失败分析。 黄色框来自最终连通区域；误差图展示大面积 FP 与小目标 FN。

接在原始鱼眼域处理并显式加入几何编码，是优于先校正再反投影的路线。完整模型在综合 F1、召回率和边缘区域 F1 上均显著优于传统 baseline，证明多源深度证据融合是处理鱼眼运动分割问题的有效方向。

References

[1] Ho Kei Cheng, Seoung Wug Oh, Brian Price, Alexander Schwing, and Joon-Young Lee. Putting the object back into video object seg-

mentation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

- [2] Mingxing Li, Jia Chen, Zihan Wang, et al. Segment any motion in videos. *arXiv preprint arXiv:2503.22268*, 2025.
- [3] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. DinoV2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.
- [4] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, et al. Sam 2: Segment anything in images and videos. *arXiv preprint arXiv:2408.00714*, 2024.
- [5] Zachary Teed and Jia Deng. Raft: Recurrent all-pairs field transforms for optical flow. In *European Conference on Computer Vision*, 2020.
- [6] Yihan Wang et al. Sea-raft: Simple, efficient, accurate raft for optical flow. *arXiv preprint arXiv:2405.14793*, 2024.