

FisheyeMotion: 融合深度光流、语义先验与可提示分割的鱼眼视频运动区域抽象

Zhuang Jiahan

Tongji University

https://github.com/FerdinandClooney/fisheye_motion

摘要

鱼眼视频具备大视场优势，但强径向畸变会改变目标尺度、边界形态与表观运动，使传统帧差或单一光流阈值在边缘区域产生大量误检。本文提出 **FisheyeMotion**，一个面向鱼眼相邻帧运动区域抽象与短时目标跟踪的 GPU 深度学习系统。系统融合 RAFT 深度光流、YOLO26-seg 实例先验、DINOv2 语义变化先验、鱼眼几何图、边界先验、自训练 FisheyeMotionNet、测试时增强不确定性融合与 SAM2.1 掩膜细化。最终模型 Full-RAFT-YOLO-DINO-FMN-SAM2 在 19 个测试样本上取得 IoU 0.3131、Precision 0.3613、Recall 0.5830、F1 0.3932；相比 YOLO-only 的 F1 0.3292 提升 0.0640，相比 FrameDiff 的 F1 0.0658 提升 0.3274。区域评估显示中心、中间、边缘 F1 分别为 0.4012、0.3471、0.2915，表明深度运动、语义、几何与边界提示对鱼眼畸变场景具有互补价值。

1 引言

运动区域抽象是视频理解、移动机器人感知和智能交通监控中的基础问题。鱼眼镜头的大视场使其适合城市道路和车载场景，但投影畸变也带来三个困难：第一，目标形状随半径非线性拉伸；第二，相同真实运动在图像平面中可能呈现不同光流幅值；第三，边缘区域的标注、实例边界与跟踪框更不稳定。

因此，本项目不把任务简化成帧差阈值或光流阈值，而是将多种模型证据联合学习。RAFT 提供稠密运动，YOLO26-seg 提供实例先验，DINOv2 提供语义变化，鱼眼标定生成径向几何图，SAM2.1 用于 promptable mask refinement。图 1 展示了完整链路。

2 相关工作

光流估计。 RAFT [5] 通过 all-pairs correlation volume 与循环更新显著提高光流质量，后续 SEA-RAFT [6]

进一步提升效率。本文使用 RAFT large 作为深度运动底座，但不直接阈值化光流，而是将其作为网络输入与跟踪传播线索。

视频分割与提示分割。 Cutie [1] 代表的视频目标分割方法强调对象记忆和跨帧传播；SAM2 [4] 则将 promptable segmentation 扩展到图像和视频。本文数据主要是相邻帧 pair，因此使用短时传播替代长时记忆，并让 SAM2.1 专注于边界细化，而非独立判断运动属性。

语义先验。 DINOv2 [3] 的自监督 patch token 具有良好的语义聚类能力。受 “Segment Any Motion in Videos” [2] 中运动线索、DINO 表征与 SAM 掩膜 densification 结合思想启发，本文将 DINOv2 semantic saliency/change 作为小样本运动分割的重要补充。

3 方法

3.1 鱼眼几何建模

给定标定 JSON 中的主点与径向参数，本文为每个像素生成归一化半径与极角编码：

$$r = \frac{\sqrt{(x - c_x)^2 + (y - c_y)^2}}{r_{\max}}, \quad g(x, y) = [r, \sin \theta, \cos \theta]. \quad (1)$$

评估时按 $r < 0.35$ 、 $0.35 \leq r < 0.70$ 、 $r \geq 0.70$ 划分中心、中间与边缘区域，以验证模型对畸变强度变化的鲁棒性。

3.2 深度证据提取

RAFT 输出 $u, v, |f|, \angle f$ 四通道光流；YOLO26-seg 输出 objectness mask 与 boxes；DINOv2 输出当前帧 semantic saliency 与前后帧 semantic change；边界先验由 Canny 边缘和帧差 Sobel 梯度组合得到。图 2 展示了同一样本上的真实缓存证据。

Motion is not decided by a single threshold: geometric distortion, dense flow, object priors, semantic change and boundary evidence are learned jointly.




图 1: FisheyeMotionNet 总体架构。系统不是用单一阈值判断运动，而是将 RAFT 光流、YOLO 实例先验、DINOv2 语义变化、边界先验和鱼眼几何图共同输入 FisheyeMotionNet，再通过不确定性融合与 SAM2.1 prompt refinement 得到最终运动掩膜和短时轨迹。

3.3 FisheyeMotionNet

FisheyeMotionNet 是一个 Attention U-Net 风格的监督运动分割网络，输入共 18 通道：

$$X = [I_{t-1}^{rgb}, I_t^{rgb}, |I_t - I_{t-1}|, f_{RAFT}, M_{YOLO}, P_{DINO}^{sal}, P_{DINO}^{chg}, P_{edge}, g(x, y)]. \quad (2)$$

训练损失为边界加权 BCE、Dice loss 与 boundary loss 的组合：

$$\mathcal{L} = \mathcal{L}_{BCE}^w + \lambda_d \mathcal{L}_{Dice} + \lambda_b \mathcal{L}_{Boundary}. \quad (3)$$

其中边界权重由 GT 膨胀边缘生成，用于缓解运动目标细边界在背景中被淹没的问题。

3.4 不确定性融合与 SAM2 细化

推理时使用原图与水平翻转两路 TTA，均值作为概率图，标准差作为 epistemic uncertainty。融合分数为：

$$S = w_n P_{net} + w_f P_{flow} + w_y P_{yolo} + w_d P_{dino} + w_e P_{edge} - w_u U. \quad (4)$$

高置信点、运动框和 YOLO 框共同作为 SAM2.1 prompts。这样 SAM2 负责边界 densification，运动属性仍由 FisheyeMotionNet 与深度证据决定。

4 实验设置

数据集来自 homework2.zip，包含当前帧、前一帧、GT 掩膜和鱼眼标定文件。固定随机种子 42，训练/验

表 1: 测试集主结果。Full 模型在综合 F1、中心/中间/边缘区域均表现最稳定。

Method	IoU	Prec.	Rec.	F1
FrameDiff	0.0376	0.0534	0.4058	0.0658
Farneback	0.0147	0.0298	0.1072	0.0275
RAFT-only	0.0264	0.0512	0.1151	0.0462
YOLO-only	0.2384	0.2588	0.5933	0.3292
FisheyeMotionNet	0.2771	0.3964	0.4043	0.3590
Full	0.3131	0.3613	0.5830	0.3932

证/测试比例为 70/15/15，测试集共 19 个样本。所有训练和推理强制使用 GPU；若 torch.cuda.is_available() 为 false，程序直接停止。实验硬件为 RTX 4060 Laptop 8GB，默认分辨率 640×480，batch size 为 2。

5 结果

表 1 表明，传统方法在鱼眼视频中明显不足。FrameDiff 召回较高但 precision 很低，说明其容易把光照变化、静态边缘和镜头遮挡误判为运动。YOLO-only 具备较强实例召回，但不能区分静止目标和运动目标。Full 模型在 precision 与 recall 之间取得更好平衡。

5.1 区域与消融

图 4 给出全图、中心、中间和边缘区域的 F1 矩阵。Full 模型边缘 F1 为 0.2915，显著高于 FisheyeMotionNet




图 2: 真实模型证据面板。与调试式拼图不同, 该图展示了最终模型实际使用的关键证据: 当前帧、RAFT 光流、YOLO objectness、DINOv2 semantic change、边界先验、最终预测、GT 与误差图。红色为 FP, 蓝色为 FN, 绿色为 TP。

单体的 0.1445; 去掉 RAFT 后边缘 F1 降至 0.1677, 去掉几何图后降至 0.1869, 说明边缘区域最依赖深度光流与显式几何建模。去掉 DINOv2 后整体 F1 下降到 0.2804, 说明语义变化先验在小样本训练中确实提供了补充监督。

5.2 定性结果

图 5 给出最佳、中位和困难边缘样本。结果显示模型能够捕获车辆、行人与边缘小目标, 但仍会在车体反光、镜头遮挡和远处细小行人处产生 FP/FN。

5.3 跟踪与失败模式

短时跟踪由最终掩膜连通域、YOLO/SAM2 观测框和 RAFT 传播中心共同决定。图 6 展示了一个典型困难

样本: 模型能稳定框出若干运动目标, 但大面积车体/镜头底部区域仍可能被误分割; 远处小行人和边缘区域则容易漏检。

6 讨论

本项目的核心结论是: 鱼眼运动分割不是“运动强度足够大就属于前景”的问题。RAFT-only 和 Farneback-only 失败说明光流幅值缺少语义和实例约束; YOLO-only 的高召回低精度说明实例检测缺少运动属性; SAM2-FrameDiff 的弱表现说明 promptable segmentation 依赖 prompt 质量。最终 Full 模型把运动、实例、语义、边界和几何统一到一个监督网络与 prompt refinement 链路




图 3: 有意义的 **baseline** 排名。仅保留确实可比较的方法，避免用没有信息量的单柱状图堆砌篇幅。

中，因此取得最高综合 F1。

7 局限与未来工作

当前数据主要是相邻帧 pair，因此跟踪评估只能覆盖短时关联，不能严格评估 IDF1、HOTA 或长时遮挡恢复。其次，Full 模型仍对 YOLO 先验依赖较强，no-YOLO 消融表现很弱。后续可引入长视频记忆网络、基于 DINO/SAM 的伪标签扩增、畸变感知 transformer decoder，以及更系统的校正域/鱼眼域双路线训练。

8 结论

本文完成了一个 GPU 深度模型主导的鱼眼视频运动区域抽象系统。通过 RAFT、YOLO、DINOv2、几何图、边界先验、FisheyeMotionNet、TTA uncertainty 与 SAM2.1 的协同，最终模型显著优于传统帧差、Farneback、RAFT-only 和 YOLO-only baseline。更重要的是，区域消融和真实样例图表明，模型提升主要来自对鱼眼边缘畸变区域的更强建模，而不是简单指标包装。

参考文献

- [1] Ho Kei Cheng, Seoung Wug Oh, Brian Price, Alexander Schwing, and Joon-Young Lee. Putting the object back into video object segmentation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.
- [2] Mingxing Li, Jia Chen, Zihan Wang, et al. Segment any motion in videos. *arXiv preprint arXiv:2503.22268*, 2025.
- [3] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov,

Region-aware F1: what each module contributes




图 4: 区域感知消融矩阵。行为不同方法或去模块版本，列为全图/中心/中间/边缘 F1。该图直接呈现哪些模块改善了鱼眼畸变最强的边缘区域。

Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.

- [4] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, et al. Sam 2: Segment anything in images and videos. *arXiv preprint arXiv:2408.00714*, 2024.
- [5] Zachary Teed and Jia Deng. Raft: Recurrent all-pairs field transforms for optical flow. In *European Conference on Computer Vision*, 2020.
- [6] Yihan Wang et al. Sea-raft: Simple, efficient, accurate raft for optical flow. *arXiv preprint arXiv:2405.14793*, 2024.




图 5: 真实样例定性比较。每行是一个测试样本, 依次展示当前帧、GT、Full 模型预测和像素级误差。该图比单纯指标图更能说明模型在大目标、小目标和边缘畸变区域的行为。




图 6: 短时跟踪与失败分析。黄色框来自最终连通区域, 误差图显示大面积 FP 与小目标 FN。该图明确指出后续提升方向: 长时 VOS memory、畸变感知 transformer head 与更强的 negative sampling。